資料庫管理期末專案計劃書：注音輸入法詞庫共享平台

Oct 30, 2026 · @lno

組別： 第 4 組　**課程：** 資料庫管理（115-1）

學號	姓名
B13303079	闕以諾
B13705036	劉威廷
B13701220	顧懷允
B13701230	周緯倫

1. 專案簡介

我們要做「輕注音詞庫平台」：讓注音輸入法的使用者同步個人詞、分享新詞、投票與回報錯詞，詞庫編輯審核後把新詞發布到下一版詞庫。資料庫有 16 張表，詞庫部分是超過 230 萬筆真實資料。

輕注音是已上線的 macOS / Windows 輸入法，每個字只打第一個注音（ㄐㄏㄇ → 你好嗎）。它的詞庫來自新酷音，漏掉的新詞（網路用語、地名、專有名詞）要靠使用者回報。目前系統只有 6 張表、一位管理員，沒有帳號、投票、回報與版本紀錄。本專案把它擴充成多使用者、多編輯的平台，每個新功能都對應一個現在做不到的需求（第 2 節）。

需要它的人：每天打中文、常遇到「詞庫沒有這個詞」的使用者，以及維護詞庫、想知道哪些詞該加的編輯。

2. 系統分析

系統有兩種登入角色：一般使用者與詞庫編輯（業務經營者）。資料分析師與系統管理員直接使用資料庫，不登入系統。註冊、登入、改密碼與一般系統相同，不再說明。

2.1 一般使用者

功能	做法	解決的需求
綁定裝置	輸入法產生裝置碼，登入後綁到帳號；未登入也能匿名分享	一人多台電腦，資料要歸到同一人

功能	做法	解決的需求
個人詞同步	新增、修改、刪除自己的詞；各裝置每小時取回變更，包含刪除	換電腦不必重加自己的詞
分享新詞	輸入法自動上傳詞庫沒有、但使用者選過的詞與次數；也可在網頁投稿	編輯不必自己找新詞
投票	對待審新詞按讚或倒讚，每人每詞一票，可改可收回	只看使用次數，分不出好詞和打錯的字
查詞	用詞、完整注音或首字注音（ㄐㄏㄇ）查正式詞庫，看讀音、詞頻、常接的詞	打不出某詞時，先查有沒有收錄、讀音對不對
回報錯詞	對正式詞條回報「讀音錯」「不是詞」「不當用語」，追蹤處理狀態	現在發現錯誤只能寄信，無法追蹤
訂閱詞庫包	訂閱主題詞包（台灣地名、醫學用語），同步時一併下載	專業用詞放進主詞庫會干擾一般人的候選

2.2 詞庫編輯（業務經營者）

功能	做法	解決的需求
審核新詞	依使用次數、裝置數、票數排序待審詞，標記加入、不要或封鎖；加入前須查字典填完整注音；可批次	投稿太多，要先看最多人用的；封鎖的詞不再收投稿
新詞名額	每版詞庫設新詞上限（例：200 個），額滿後加入的詞排入下一版	每個新詞發布前都要實測候選排序，名額控制測試量
維護正式詞庫	新增讀音、調整詞頻、停用詞條	修正候選排序與錯音
處理回報	接下回報，修正詞條或駁回	每筆回報都有人負責、有結果
發布詞庫版本	把草稿版本的變更發布成新版（例：7.2），輸入法更新時套用；每版留變更清單	出問題時查得到哪一版加了哪個詞
管理詞庫包	建立、編輯、上架、下架主題詞包	讓專業用詞有地方放
管理使用者	停權洗票或亢亂投稿的帳號	票數才可信
統計面板	待審數、近 7 天活躍裝置、各版本輸入法的使用比例	決定何時發新版、何時停止支援舊版

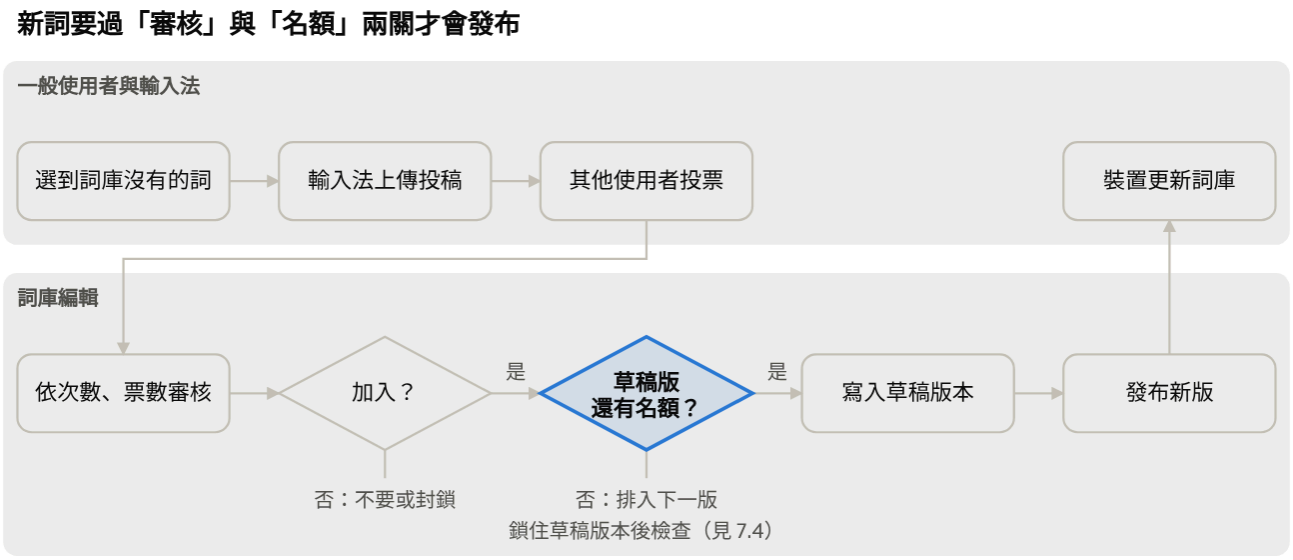
2.3 資料分析（不在系統上）

分析師直接對資料庫下查詢，預計做這 6 個分析：

分析	用到的資料	幫助的決定
很多裝置在用、却還沒審的詞	submissions、devices、word_reviews	先審哪些詞
使用次數與票數差很多的詞	submissions、votes	找出洗票或常被打錯的詞
各資料來源被回報的比例與類型	reports、lexicon_entries、sources	哪個來源要優先整理
編輯從第一次投稿到審核的天數	word_reviews、submissions、users	審核人力夠不夠

分析	用到的資料	幫助的決定
常排在第 5 個候選之後才被選中的正式詞	MongoDB 選字事件、lexicon_entries	哪些詞頻該調高
各版新詞發布後實際被選用的次數	MongoDB 選字事件、release_changes	審核標準要放寬還是收緊

2.4 新詞在角色間的流動



新詞流程 · 兩種角色、兩個關卡

使用者產生投稿與票數，編輯審核後把詞放進有名額限制的草稿版本，發布後回到每位使用者的裝置。

3. 系統架構

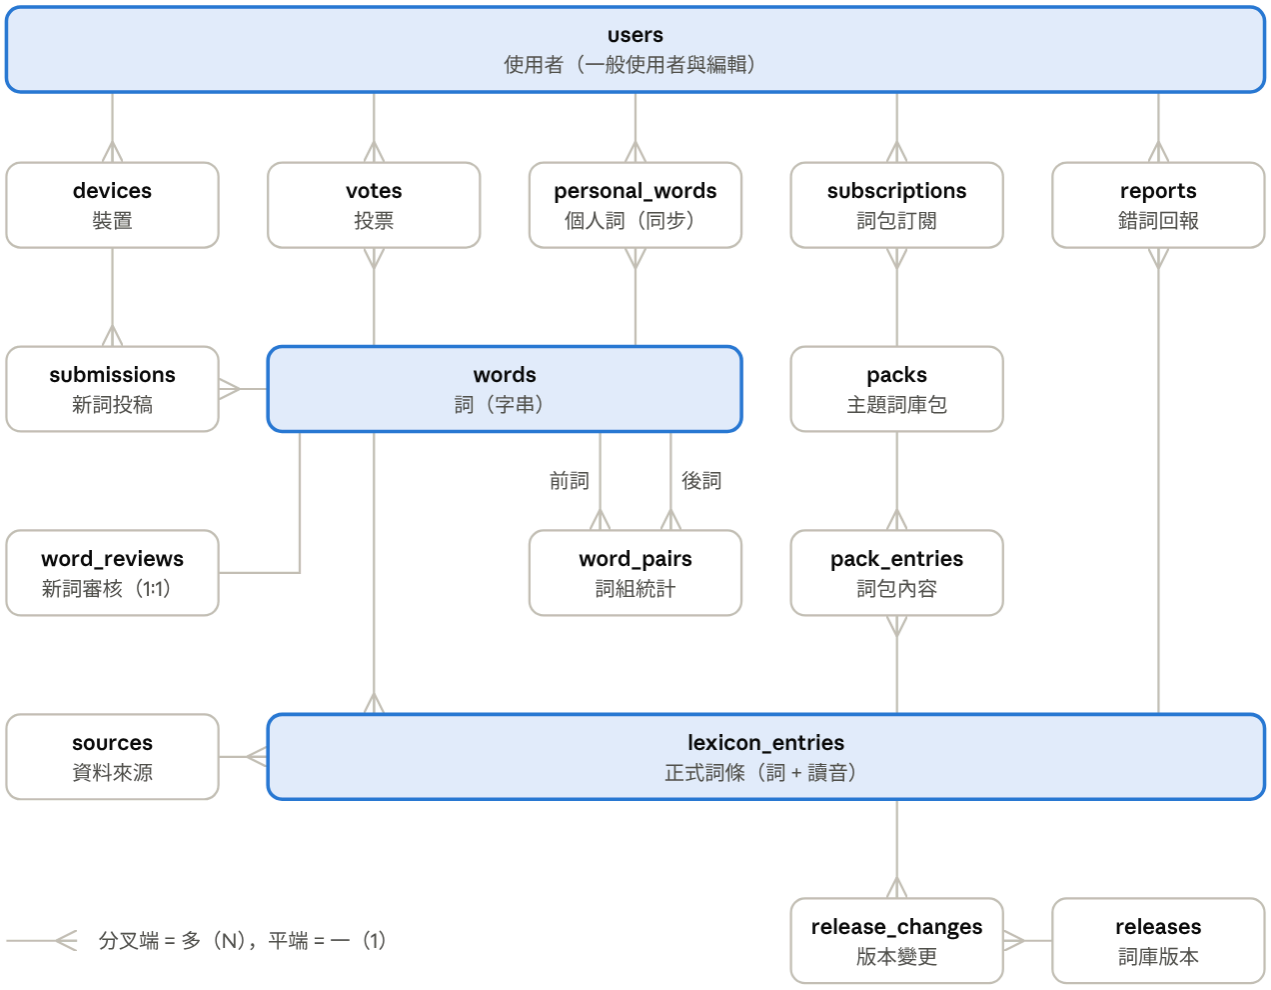
系統是 client-server 架構，前端只透過 REST API（JSON）存取資料。

層	技術	內容
前端	網頁（HTML / JavaScript）、輸入法 App	一個網頁，依登入角色顯示功能；輸入法負責上傳新詞與同步
後端	Node.js API（Vercel Functions）	驗證登入與權限、交易、寫入行為紀錄
關聯式資料庫	PostgreSQL（Neon）	帳號、詞庫、投稿、投票、回報、版本等交易資料
NoSQL	MongoDB	查詞紀錄、候選選取事件（選了第幾個候選）

行為紀錄量大、欄位會變、只新增不修改，所以放 MongoDB。展示時會開兩個網頁前端連同一後端，示範兩位編輯同時審同一個詞、兩人同時投票時資料仍正確。

4. ER Diagram

三張核心表（使用者、詞、正式詞條）串起其餘 13 張



ER diagram · 16 個實體，烏鴉腳表示多的一端

使用者透過裝置投稿新詞，對詞投票、存個人詞；一個詞有多個讀音（正式詞條），詞條可被回報、放進詞包、記入版本變更。`submissions`、`votes`、`personal_words`、`subscriptions`、`pack_entries`、`release_changes` 是多對多關係轉成的表。編輯的操作外鍵（審核者、修改者、處理者、建立者）都參照 `users`，圖中省略，見第 5 節。

5. 關聯綱要（Relational Schema）

共 16 張表。粗體為主鍵，「→」為外鍵參照的表。

#	關聯	外鍵
1	users(**user_id**, email, password_hash, display_name, role, status, created_at)	—

#	關聯	外鍵
2	devices(**device_id**, user_id, platform, app_version, first_seen, last_synced_at)	user_id → users
3	sources(**source_id**, name, license, url, version)	—
4	words(**word_id**, text, corpus_count)	—
5	lexicon_entries(**entry_id**, word_id, bopomofo, frequency, source_id, status, updated_by, updated_at, row_version)	word_id → words；source_id → sources；updated_by → users
6	word_pairs(**word_id, next_word_id**, pmi)	兩者皆 → words
7	word_reviews(**word_id**, status, reviewer_id, decided_at, row_version)	word_id → words；reviewer_id → users
8	submissions(**device_id, word_id, typed**, use_count, first_seen, last_seen)	device_id → devices；word_id → words
9	votes(**user_id, word_id**, value, voted_at)	user_id → users；word_id → words
10	reports(**report_id**, user_id, entry_id, kind, note, status, handler_id, created_at, handled_at)	user_id、handler_id → users；entry_id → lexicon_entries
11	personal_words(**user_id, word_id, bopomofo**, status, updated_at)	user_id → users；word_id → words
12	packs(**pack_id**, name, description, owner_id, status, created_at)	owner_id → users
13	pack_entries(**pack_id, entry_id**)	pack_id → packs；entry_id → lexicon_entries
14	subscriptions(**user_id, pack_id**, status, subscribed_at)	user_id → users；pack_id → packs
15	releases(**release_id**, version, status, max_new_words, created_by, published_at, note)	created_by → users
16	release_changes(**release_id, entry_id**, action, old_frequency, new_frequency)	release_id → releases；entry_id → lexicon_entries

`words` 只存「字串」，正式詞庫、投稿、投票、個人詞都參照它，所以同一個詞只存一次。一個詞可有多個讀音（例：「覺得」ㄐㄩㄝˊ ㄉㄜˊ / ㄐㄩㄝˊ ㄉㄜ˙），每個讀音是一筆 `lexicon_entries`。

6. 資料字典

所有時間欄位為 `timestamptz`，預設 `now()`。未註明 NULL 的欄位皆為 NOT NULL。

欄位	型別	限制	說明
users.user_id	bigint	PK，自動編號	使用者
users.email	text	UNIQUE，小寫	登入帳號
users.password_hash	text		scrypt 雜湊
users.display_name	text	1–30 字	顯示名稱
users.role	text	user / editor	角色
users.status	text	active / suspended / deleted	帳號狀態
users.created_at	timestamptz		註冊時間
devices.device_id	uuid	PK	輸入法產生的裝置碼
devices.user_id	bigint	FK，NULL	綁定的帳號；NULL = 匿名
devices.platform	text	macos / windows	作業系統
devices.app_version	text		輸入法版本，例 7.1
devices.first_seen / last_synced_at	timestamptz		首次連線 / 最後同步
sources.source_id	smallint	PK	資料來源
sources.name	text	UNIQUE	例：新酷音 tsi.csv、使用者投稿
sources.license / url / version	text	NULL	授權、出處、版本
words.word_id	bigint	PK	詞
words.text	text	UNIQUE，1–20 個漢字	詞的字串
words.corpus_count	bigint	≥ 0，預設 0	FineWeb-2 語料中的出現次數

欄位	型別	限制	說明
lexicon_entries.entry_id	bigint	PK	正式詞條（詞 + 讀音）
lexicon_entries.word_id	bigint	FK，UNIQUE(word_id, bopomofo)	詞
lexicon_entries.bopomofo	text	注音符號與空格	完整讀音
lexicon_entries.frequency	integer	≥ 0	詞頻，影響候選排序
lexicon_entries.source_id	smallint	FK	來源
lexicon_entries.status	text	active / retired	停用不刪除
lexicon_entries.updated_by	bigint	FK，NULL	最後修改的編輯
lexicon_entries.updated_at	timestamptz		最後修改時間
lexicon_entries.row_version	integer	預設 1	樂觀鎖版本號
word_pairs.word_id / next_word_id	bigint	PK，FK	前詞、後詞
word_pairs.pmi	numeric(3,1)		點互資訊，整句轉換加分
word_reviews.word_id	bigint	PK，FK	被審的詞
word_reviews.status	text	pending / approved / rejected / blocked	審核狀態
word_reviews.reviewer_id	bigint	FK，NULL	審核的編輯
word_reviews.decided_at	timestamptz	NULL	審核時間
word_reviews.row_version	integer	預設 1	樂觀鎖版本號
submissions.device_id / word_id	uuid / bigint	PK，FK	上傳的裝置、詞
submissions.typed	text	PK，1–60 個注音符號	使用者打的注音（可只打首字）
submissions.use_count	integer	1–1,000,000	累計選用次數
submissions.first_seen / last_seen	timestamptz		第一次 / 最後一次上傳
votes.user_id / word_id	bigint	PK，FK	投票者、詞

欄位	型別	限制	說明
votes.value	smallint	1 / -1	讚 / 倒讚
votes.voted_at	timestamptz		投票時間
reports.report_id	bigint	PK	回報
reports.user_id / entry_id	bigint	FK	回報者、被回報的詞條
reports.kind	text	wrong_reading / not_word / offensive	回報類型
reports.note	text	NULL，≤ 200 字	補充說明
reports.status	text	open / resolved / dismissed	處理狀態
reports.handler_id	bigint	FK，NULL	處理的編輯
reports.created_at / handled_at	timestamptz	handled_at NULL	回報 / 處理時間
personal_words.user_id / word_id	bigint	PK，FK	使用者、詞
personal_words.bopomofo	text	PK	讀音
personal_words.status	text	active / deleted	deleted 是同步用的刪除標記
personal_words.updated_at	timestamptz		裝置依此取回變更
packs.pack_id	bigint	PK	詞庫包
packs.name	text	UNIQUE	名稱
packs.description	text	NULL	說明
packs.owner_id	bigint	FK	建立的編輯
packs.status	text	draft / published / archived	上架狀態
packs.created_at	timestamptz		建立時間
pack_entries.pack_id / entry_id	bigint	PK，FK	詞包內的詞條
subscriptions.user_id / pack_id	bigint	PK，FK	訂閱者、詞包
subscriptions.status	text	active / cancelled	訂閱狀態
subscriptions.subscribed_at	timestamptz		訂閱時間

欄位	型別	限制	說明
releases.release_id	bigint	PK	詞庫版本
releases.version	text	UNIQUE	例：7.2
releases.status	text	draft / published	草稿可改，發布後不可改
releases.max_new_words	integer	> 0，預設 200	這一版最多加入的新詞數（新詞名額）
releases.created_by	bigint	FK	建立的編輯
releases.published_at	timestamptz	NULL	發布時間
releases.note	text	NULL	版本說明
release_changes.release_id / entry_id	bigint	PK，FK	版本、詞條
release_changes.action	text	add / remove / reweight	變更類型
release_changes.old_frequency / new_frequency	integer	NULL	變更前後詞頻（add 無舊值、remove 無新值）

7. 正規化、索引與刪除策略

7.1 正規化

16 張表都達 BCNF：每個函數相依的左邊都是候選鍵。主鍵以外的候選鍵（`users.email`、`words.text`、`lexicon_entries` 的 (word_id, bopomofo)、`packs.name`、`releases.version`）也都能決定整列。幾個刻意的決定：

- **詞字串獨立成 `words`**：舊版把「詞」重複存在 5 張表，改字要改 5 處。現在只存一次。
- **`submissions` 不存 user_id**：它可由 device_id 查到，存了會造成遞移相依，裝置改綁帳號時也會不一致。
- **審核獨立成 `word_reviews`**：大多數詞（正式詞庫）不需審核，放進 `words` 會有大量 NULL。
- **票數不存在詞上**：由 `votes` 即時計算，避免同時投票時計數不一致。

- **去正規化的取捨**：待審列表要把 `submissions` 與 `votes` 合併加總，資料一大就慢。我們會比較「即時加總」與「每小時更新的 materialized view `candidate_stats`」，用後者時接受最多 1 小時的延遲。

設計目標：

- **一致性**：用 FK、CHECK、UNIQUE 在資料庫層擋住錯誤資料，不只靠程式檢查。
- **擴充性**：新資料來源只要多一筆 `sources`；新主題詞包不必改綱要；狀態值用 CHECK 限制，增加狀態只改一條限制。
- **易懂**：表名與欄位用英文全名，多對多的表都以兩邊的實體命名。

7.2 索引

主鍵與 UNIQUE 已有索引，另建：

索引	用途
`lexicon_entries (bopomofo text_pattern_ops)`	用注音前綴查詞
`words USING gin (text gin_trgm_ops)`	用詞的一部分查詞
`submissions (word_id)`	依詞加總使用次數與裝置數
`votes (word_id)`	依詞加總票數
`word_reviews (word_id) WHERE status = 'pending'`	部分索引，只含待審詞
`personal_words (user_id, updated_at)`	裝置取回某時間後的變更
`reports (status, created_at)`	編輯看未處理回報
`devices (user_id)`、`devices (last_synced_at)`	帳號的裝置、活躍裝置統計

期末會用 `EXPLAIN ANALYZE` 比較有無索引的執行時間，對象是 200 萬筆的 `word_pairs` 與待審列表查詢。

7.3 狀態欄位與刪除

所有外鍵都用 `ON DELETE RESTRICT`，只有 `pack_entries` 與 `release_changes` 跟著父表 `CASCADE`。各表「刪除」的做法：

資料	做法	理由
帳號	status = deleted，清空 email 與名稱	保留投票、回報、審核紀錄

資料	做法	理由
正式詞條	status = retired	舊版本的變更清單仍參照它
個人詞	status = deleted	其他裝置同步時要知道它被刪了
封鎖的新詞	word_reviews.status = blocked	舊版直接 DELETE 投稿，無法還原；現在保留
詞包、訂閱、回報	status 欄位	保留歷史供分析
投票	真的 DELETE	收回一票不需留紀錄

7.4 交易與併行控制

預設隔離等級為 READ COMMITTED，會衝突的地方另外加鎖：

- **新詞名額（最容易衝突）**：兩位編輯同時把詞加入只剩 1 個名額的版本，就像訂票超賣。交易內先 `SELECT … FROM releases WHERE status = 'draft' FOR UPDATE` 鎖住草稿版本，再數 `release_changes` 中 action = 'add' 的筆數，未滿才寫入。後到的編輯會等前一個交易結束，看到額滿就排入下一版。期末會用腳本同時送 100 個加入請求，證明不會超額。
- **兩位編輯同時審同一詞**：用 `row_version` 做樂觀鎖，`UPDATE … WHERE row_version = $舊值` 改到 0 筆就告知已被他人審過。
- **加入新詞**：更新 `word_reviews`、新增 `lexicon_entries`、寫入 `release_changes` 在同一個交易，任一步失敗就全部回復。
- **同時投票、同時上傳**：`INSERT … ON CONFLICT DO UPDATE`，使用次數用 `use_count = use_count + EXCLUDED.use_count` 累加，不會遺失更新。
- **發布版本**：與加入新詞搭同一個草稿版本的鎖，發布時不會有新變更插進來。

8. 資料來源與預估筆數

詞庫類的表全是真實資料，最大的 `word_pairs` 有 200 萬筆；使用者行為類的表用程式生成，其中 submissions 約 100 萬筆。兩張百萬筆級的表用來做索引與查詢優化的比較。

表	筆數	來源
word_pairs	2,000,000	真實：FineWeb-2 國語語料統計的前 200 萬組詞組（ODC-By 1.0）
submissions	約 1,000,000	生成：8,000 台裝置、平均每台約 125 個詞
lexicon_entries	160,340	真實：新酷音詞庫 tsi.csv（LGPL-2.1）

表	筆數	來源
words	約 170,000	真實 147,619 個詞，加上候選新詞；corpus_count 來自 FineWeb-2
personal_words	約 200,000	生成
votes	約 150,000	生成
word_reviews	約 20,000	生成：候選新詞取自教育部《重編國語辭典修訂本》開放資料中新酷音沒有的詞
subscriptions	約 12,000	生成
devices	約 8,000	生成
pack_entries	約 6,000	從真實詞庫挑選
users	5,000	生成
reports	約 3,000	生成
release_changes	約 2,000	真實調整檔 lexicon-adjustments.csv，加上生成
packs	12	編輯建立
releases	9	真實：已發布的 v0.1.0–v7.1
sources	4	真實：新酷音、FineWeb-2、使用者投稿、編輯

生成原則：使用次數與投票數照長尾（Zipf）分布，少數詞被大量使用；約 30% 裝置不綁帳號；個人詞的讀音由真實詞庫推得；時間分布在 2026 全年，平日比假日多。所有生成資料都符合第 6 節的限制。